

论安全关键人工智能系统中决策主体的形成机制

——兼评当前大模型研究中的认识论盲区

摘要

当前大模型研究将"减少幻觉"视为技术优化目标，却未追问幻觉的结构性根源。本文指出：大模型幻觉的必然性，在于其概率生成机制与"判断必须以事实为依据"这一常识的结构性背离。大模型只有公共知识的统计分布，没有绑定于具体系统的私域事实层；只有借来的、公共的、平均化的应然，没有"我是谁"的实然来锚定。本文提出TDA（Three-layer Dialectical Architecture，三层辩证架构），又称元受动极架构，其核心组件为空模型——以"空模型"承载私域事实、"结构化辩论层"构建应然-实然张力、"裁决AI"实现动态阈值下的存在论决断，从而在安全关键系统中形成可审计、可追溯的最终决策主体。本文已完成TDA核心机制的仿真验证，并提供静态事实约束与动态事实采集的参考实现及完整实验设计，期待产业界与开源社区共同推进跨场景验证。本文的核心论点是：高可靠AI的安全前提不是"模型完美"，而是在接受结构性不完美的条件下，建立"判断归机、目的归人"的主体形成机制。

关键词：决策主体；私域事实；概率-确定性桥接；元受动极；TDA架构；空模型范式；安全关键系统

一、问题的提出：一个被回避的基础问题

1.1 当前研究的盲区

2025年9月，OpenAI发表《Why Language Models Hallucinate》，系统分析了语言模型幻觉的各类技术原因，并提出若干缓解方向。该文被广泛引为"开创性工作"。

然而，该文及同类研究的共同特征是：**在"知其然"层面详尽，在"知其所以然"层面缺席**。它们分析幻觉的触发条件、统计特征、训练偏差，却未追问一个更根本的问题：

为什么概率生成系统必然产生幻觉？

答案其实很简单：**因为概率不是事实，逻辑推演不是判断**。

大模型的运作机制是：在公共语料中习得词语的共现概率，在查询时输出概率最高的序列。它所做的不是"判断"，而是在**不知道事实的情况下，模拟判断的语言形式**。当事实与概率冲突时，模型服从概率；当事实缺失时，模型用概率填补空白——这就是幻觉。

1.2 常识的缺席

"判断必须以事实为依据"，这不是哲学命题，是常识。

- 医生诊断，依据的是病历（事实），不是医学论文的概率分布
- 法官裁判，依据的是证据（事实），不是法条的语义相似度
- 飞行员决策，依据的是仪表读数（事实），不是飞行手册的文本生成

这些事实的共同特征是：**私域的、绑定的、相对确定的、随时间可变的**。

- 私域**：我的病历，不是你的；这台设备的参数，不是那台的
- 绑定**：与具体系统、具体时刻、具体位置相关联
- 相对确定**：在判断当下是静态的，可视为"给定"
- 随时可变**：病历新增、设备更换、规则修改，必须跟踪

大模型没有这些。它有"知识"——公共的、通用的、统计的——但没有"事实"。

1.3 问题的紧迫性

当大模型被用于聊天、写作、创意生成时，幻觉是"可接受的不完美"。但当它被用于自动驾驶、医疗诊断、金融风控、司法辅助时，幻觉就是**结构性风险**。

当前的安全策略——RLHF对齐、Constitutional AI、护栏规则、人工审核——都在**概率层面打转**：

- RLHF对齐的是"人类偏好"，不是事实约束
- Constitutional AI约束的是"应该说什么"，不是"事实是什么"
- 护栏规则是事后过滤，不是前置约束
- 人工审核是人力兜底，不是机制保障

这些策略的共同盲区是：**未将"事实"作为独立的、不可取消的架构层**。

二、理论框架：决策主体的形成条件

2.1 "主体"的界定

本文不讨论"AI是否有意识"这一本体论问题。本文讨论的是**功能层面的"决策主体"**：一个系统，若其输出被作为"最终决定"采纳，则在该场景下构成决策主体。

关键问题是：**这个主体资格从何而来？**

当前实践的隐含答案是：**能力达标即授权**。模型通过测试，即被部署为决策主体。但这个逻辑回避了一个问题：**测试通过，不等于事实约束到位**。

2.2 判断的结构

人的判断，以"实然-应然-裁决"为结构：

要素	说明	例子
实然	"我是谁"——身份、处境、约束	"我是收藏家""我是极简主义者"
应然	"我要什么"——价值方向、目标	"有价值要收藏""占地方是累赘"
裁决	在张力中的动态选择	要/不要

核心命题：应然本身没有根基。根基是实然给的。

没有实然，应然就是空的——不是"没有根基"，是**没有内容**。

例：同一古董。

- 实然A："我是收藏家，有仓库，有保养能力"→应然："有价值要收藏"→裁决：要
- 实然B："我是极简主义者，住小户型，搬家频繁"→应然："占地方是累赘"→裁决：不要

同一实然（古董存在），不同实然（我是谁），不同应然（我要什么），不同裁决。

2.3 大模型的结构缺陷

人的判断	大模型的输出
实然："我是谁"（身份、处境、约束）	无实然 ——没有身体，没有身份，没有位置
应然：从实然中生长出来	应然是借来的 ——从训练数据中的统计偏好
裁决：扎根于"我"的决断	裁决是概率采样 ——没有"我"

大模型不是没有应然，是它的应然没有锚点——不知道"我是谁"，所以"我要什么"是飘着的。

例：大模型面对古董，输出"具有历史价值，建议收藏"——这是公共知识的平均化表述，不是判断。它不知道"我是谁"，所以无法决断"我要不要"。

特征	说明
核心原则	本身不生成内容，只做空校验、空拦截、空增强
比喻	像安检门——"空"着，但通过规则过滤一切
部署	可插拔到任何LLM，任何终端
事实库	非通用、领域专属、按行业/场景/用户个性化定制

关键区分：

	知识	事实
通用性	通用	私域、绑定、定制
来源	公共语料	本地终端、用户数据
可争论性	可争论	不可争论，必须响应
空模型处理	不处理	专门处理

不是"知识库"。知识库是公共的、可检索的、可争论的。空模型是**绑定于具体系统的、不可争论的、作为约束条件的事实集合**。

知识库	空模型
"人类正常体温约37°C"	"该患者当前体温38.5°C"
"青霉素可治疗细菌感染"	"该患者对青霉素过敏"
"古董具有收藏价值"	"我是收藏家，有仓库" / "我是极简主义者，住小户型"

关键区别：空模型的事实，不是"供参考"，是**必须响应**。它回答"我是谁"，从而锚定"我要什么"。LLM的输出若与空模型冲突，进入辩论层；若辩论无法消解，熔断器介入。

3.3 结构化辩论层：应然-实然的张力机制

LLM的应然输出与空模型的实然约束，在辩论层形成**冲突图**：

- 节点：应然命题、实然事实
- 边：支持、反对、中立
- 权重：动态调整，基于历史先验和当前语境

辩论不是"谁说服谁"，是**让冲突显式化、结构化、可审计**。

3.4 裁决AI：动态阈值下的存在论决断

不是优化，是**裁决**。

优化	裁决
目标函数最小化	约束条件下的存在论决断
可重复	有依据的随机（同一冲突，不同语境可能不同裁决）
无责任	可追溯至具体阈值和历史先验

动态阈值τ：根据系统状态、历史误报/漏报、外部审计反馈，动态调整。τ不是超参数，是**系统自我维持的调节机制**。

3.5 非认知结构性熔断器：实然的最高否决权

不是规则引擎，不是分类器。是**存在论层面的中断**：

- 当实然约束与应然输出存在不可消解冲突时
- 当裁决AI的置信度低于动态阈值时
- 当人工审计触发最高否决权时

熔断器直接中断输出，不经过LLM的语义消解。这是"实然作为最高指令"的结构化实现。

3.6 外挂扬弃记忆：错误的结构化丢弃

不是"微调", 不是"持续学习"。是对错误案例的显式扬弃：

- 误报/漏案例进入外挂记忆
- 定期审计，确认错误模式
- 更新判例库，但不污染LLM主参数
- LLM的"遗忘"是困难的、不可控的；外挂扬弃是显式的、结构化的、可审计的

3.7 主体形成机制

层级	功能	归属
目的	为什么做这个判断	人
事实	"我是谁"——身份、处境、约束	空模型（绑定系统）
裁决	在张力中如何选择	裁决AI（机器）
审计	对不对、能不能过	人+熔断器
责任	出事了谁负责	可追溯至每层

"判断归机、目的归人"：机器做判断，但判断的根基（目的+事实）来自人；机器不拥有目的，但机器的判断必须接受"我是谁"的实然硬约束。

四、与现有工作的关系

4.1 不是替代，是底层约束

现有工作	元受动极的定位
Scaling Law	不改变，但接受其"结构性不完美"
RLHF	不改变，但将其输出纳入应然层，接受实然约束
RAG	不改变，但RAG检索的是公共知识，空模型承载私域事实
形式化验证	不改变，但验证的前提从"人给规范"扩展为"系统绑定事实"
人机协同	不改变，但协同的边界从"模糊分工"变为"目的归人、判断归机"

4.2 与国内院士级范式的直接对比

本文提出的TDA架构与现有主流研究形成互补而非替代关系：

范式	核心贡献	TDA的互补定位
邬江兴：内生安全（DHR多模冗余）	架构级容错——通过异构冗余实现"故障-安全"	内生安全解决架构容错，TDA解决事实锚定——冗余确保系统不崩溃，事实锚定确保系统不胡说
姚期智：可证明AGI	形式化验证行为边界——人给规范，机器证明	可证明AGI验证"是否符合规范"，TDA回答"规范从何而来"——规范应扎根于私域事实，而非人定假设
中科院：TRC（Trusted Responsible Computing）	可信计算框架——从芯片到应用的全栈可信	TRC确保计算过程可信，TDA确保计算内容可信——过程正确不等于内容正确

核心区分：上述范式均在"能动性"维度内优化——如何让系统更可靠、更可证明、更可信。TDA首次将"受动性"作为独立的、可形式化的架构层提出：系统不仅需要"做得好"，更需要"被事实约束"。

4.3 与OpenAI幻觉研究的对话

OpenAI的《Why Language Models Hallucinate》分析了幻觉的技术原因，提出缓解方向。本文指出：这些缓解方向均未能触及结构性根源。

OpenAI的方向	盲区
改进训练数据	数据再多，也是公共的，不是私域的
增加事实核查	核查是事后，不是前置约束
强化对齐	对齐的是偏好，不是事实
多模态 grounding	grounding的是感知，不是"必须响应"的约束

本文的回应：不是让模型"更像"事实，是给模型一个**必须服从的事实层**——让它知道"我是谁"，从而锚定"我要什么"。

五、限度与诚实

5.1 工具化≠本体化

本文不声称该架构让AI"有意识"。本文声称的是：**该架构在功能层面模拟了"判断以事实为依据"的结构，从而在安全关键场景中形成可审计、可追溯的决策主体。**

"类意识"不是意识，是**结构的功能等价**。

5.2 验证的困难

可验证的	不可验证的
空模型的事实覆盖度	裁决AI的"理解"
熔断器的触发频率和准确率	系统的"主观性"
判例法的收敛性	"像不像人的判断"
责任链的可追溯性	"有没有意识"

5.3 伦理前置

若该架构被采纳，需前置回答：

- 谁定义空模型的事实？（系统设计者？监管者？用户？）
- 动态阈值 τ 的调整权归谁？
- 熔断器误触发造成的损失，责任如何分配？

这些问题没有技术答案，是**政治问题**——必须在技术部署前回答。

六、实验验证路径设计

本文提出TDA架构的可验证性分三层推进，形成从核心机制到完整系统的渐进验证路径：

6.1 第一层：核心机制验证（已完成）

目标：验证动态阈值裁决机制的有效性

方法：Jigsaw Toxic Comment分类任务

结果：

方法	漏报率 (FNR)	误报率 (FPR)
纯模型A (Baseline)	31.22%	3.11%
固定阈值 $\tau=0.5$	5.41%	18.22%
固定阈值 $\tau=0.7$	10.17%	9.84%
固定阈值 $\tau=0.9$	20.15%	4.27%
TDA (动态阈值)	6.73%	6.98%

结论：动态阈值依托判例库实现场景差异化松紧调节，同步压低漏报、误报，突破固定阈值安全-可用性互斥困境。

6.2 第二层：静态事实约束验证（参考实现已开源）

目标：验证私域事实检索+冲突拦截机制

参考实现：nmp.py（Null Model Paradigm）

核心流程：

- 输入问题→空模型检索相关事实→打包为JSON→LLM在事实边界内生成→冲突校验→放行/拦截

验证要点：

- 事实召回率：检索相关事实的完整性
- 冲突检测命中率：拦截与事实矛盾输出的准确率
- 误拦截率：合法输出被错误拦截的比例

开源状态：代码已开源，社区可复现扩展。限于个人研究者资源，大规模跨领域定量评估待产业界支持。

6.3 第三层：动态事实采集验证（实验设计已完成，待执行）

目标：验证动态私域事实采集+闭环修复的完整可行性

参考实现：crash_probe.py（定向故障探针）

场景设计：系统运维故障诊断

对比框架：

	旧范式（纯LLM）	新范式（TDA）
用户输入	"游戏一直崩溃"	"游戏一直崩溃"
系统响应	列出5个猜测（驱动、DX、过热、显存、系统文件）	启动探针采集私域事实
事实采集	无	GPU状态、进程日志、崩溃转储、硬件配置
LLM分析基础	公共知识概率分布	结构化事实报告
诊断输出	泛泛而谈，用户反复尝试	根本原因定位+针对性修复建议
闭环验证	无	修复→稳定性验证

预期指标：

- 诊断准确率（根因定位正确率）
- 用户尝试次数（旧范式平均尝试次数 vs 新范式一次性解决率）
- 闭环修复成功率（建议应用后问题解决率）

资源需求：跨硬件平台的崩溃案例库、多版本驱动兼容性测试环境，超出个人研究者能力边界。

当前状态：实验设计已完成，参考实现（crash_probe.py）可运行，完整定量验证待产业算力与开源社区共同推进。

6.4 跨场景一致性声明

上述三层分别验证：

- 第一层：**裁决机制（动态阈值优于静态阈值）
- 第二层：**静态事实层（私域事实约束开放生成）
- 第三层：**动态事实层（实时状态采集驱动闭环修复）

三层组合构成TDA完整验证链条，但每层可独立评估。本研究已完成第一层，提供第二、三层的参考实现与实验设计，证明TDA架构从核心机制到工程落地的可行性路径。

七、产业落地指向

该架构可优先在以下场景开展试点：

场景	私域事实特征	责任边界敏感度
金融信贷合规	客户征信、资产负债表、监管规则	高——误判导致坏账或合规处罚
自动驾驶高精地图校验	实时路况、车辆传感器参数、地图版本	极高——误判直接危及生命安全
医疗电子病历审核	患者病史、过敏记录、用药禁忌	极高——误判导致医疗事故
司法辅助裁判	案件证据、当事人信息、适用法律	高——误判影响司法公正

共同特征：私域事实明确、责任边界敏感、现有大模型幻觉风险不可接受。

八、结论

大模型幻觉的根本原因，不是训练不足、数据不够、对齐不强，是**结构性缺失：没有私域事实层，没有"我是谁"的实然来锚定应然，没有实然作为最高指令的裁决结构。**

当前安全策略在概率层面打转，是**用技术复杂性掩盖认识论简单性。**

"元受动极"架构的提出，不是否定现有技术路线，是在**现有路线之下，建立一个不可绕过的约束层——让"判断必须以事实为依据"这一常识，成为AI系统的结构性前提。**

高可靠AI的安全前提，不是"模型完美"，是在**承认模型不完美的条件下，建立"判断归机、目的归人"的主体形成机制。**

参考文献

[1] OpenAI. Why Language Models Hallucinate. arXiv:2509.04664, 2025.

[2] Maturana, H. R., & Varela, F. J. Autopoiesis and Cognition. Reidel, 1980.

[3] Spinoza, B. Ethics. 1677. (Conatus doctrine)

[4] Heidegger, M. Being and Time. 1927. (Dasein as thrown projection)

[5] Husserl, E. Ideas Pertaining to a Pure Phenomenology. 1913. (Intentionality)

[6] Friston, K. The free-energy principle: a unified brain theory? Nature Reviews Neuroscience, 2010.

[7] Blum, M., et al. Conscious Turing Machine. arXiv:2107.13704, 2021.

[8] 邬江兴. 内生安全与拟态防御. 中国科学: 信息科学, 2018.

[9] Yao, A. C. C. 可证明安全的通用人工智能. 相关学术报告, 2023-2024.

[10] 中国科学院. 可信计算与负责任计算（TRC）框架. 相关技术白皮书, 2024.